

Predicción de Precios de Alquiler de Viviendas en India Mediante Técnicas de Aprendizaje Supervisado

Andrea Correa Arango
Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia
andrea.correaa1@udea.edu.co

Julián Isaza Marín
Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia
julian.isazam@udea.edu.co

María Cristina Vergara Quinchia
Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia
cristina.vergara1@udea.edu.co

I. DESCRIPCIÓN DEL PROBLEMA

El acceso a la vivienda constituye una de las necesidades fundamentales del ser humano y, dentro de este contexto, el mercado del alquiler residencial desempeña un papel estratégico en las economías en desarrollo. En el caso de la India, país al que corresponde la base de datos utilizada en este proyecto, el mercado inmobiliario residencial ha experimentado un crecimiento acelerado. Este dinamismo genera una creciente demanda de herramientas que permitan estimar el valor de renta de los inmuebles de manera objetiva y eficiente.

Tradicionalmente, la fijación del precio de alquiler ha dependido de la experiencia del propietario o de agentes inmobiliarios [1], procesos que suelen estar sujetos a sesgos, asimetrías de información y falta de criterios estandarizados. Frente a esta problemática, el aprendizaje automático ha emergido como una alternativa poderosa para modelar fenómenos complejos a partir de datos históricos.

El presente trabajo aborda el problema de la predicción del precio de alquiler residencial como un problema de regresión dentro del paradigma de aprendizaje supervisado. Para ello, se implementarán y compararán diferentes técnicas de aprendizaje automático, entre las que se incluyen Regresión Lineal, K-Nearest Neighbors (KNN), Support Vector Regression (SVR), Árbol de Decisión y una Red Neuronal Artificial. El objetivo principal es analizar la capacidad predictiva de estos modelos para estimar el valor de renta de las viviendas a partir de características como el tamaño del inmueble, el número de habitaciones, la cantidad de baños y la ubicación. A partir de este proceso, se busca identificar cuál de las técnicas ofrece un mejor desempeño en la predicción del precio de alquiler.

El mercado inmobiliario en la India se caracteriza por una notable diversidad, albergando opciones residenciales que van desde viviendas modestas en entornos rurales hasta complejos residenciales en grandes ciudades [2]. Esta diversidad, impulsada por el crecimiento económico del país, genera un escenario donde la fijación de precios de alquiler se vuelve una tarea compleja y, con frecuencia, carente de objetividad. Los métodos tradicionales de valoración suelen depender de la percepción subjetiva de propietarios o de comparativas limitadas con propiedades cercanas, lo que dificulta capturar la verdadera complejidad del mercado y puede derivar en ineficiencias económicas [1]. En este contexto, la implementación de técnicas de machine learning resulta de gran utilidad, ya que permite procesar y analizar

de forma simultánea múltiples variables estructurales y geográficas [3]. Un sistema predictivo automatizado proporciona una herramienta transparente y justa para inquilinos y arrendadores, eliminando sesgos humanos y optimizando la toma de decisiones en tiempo real.

Para el desarrollo de esta solución, se utilizará el House Rent Prediction Dataset publicado en 2022, el cual recopila información detallada de listados reales de viviendas en India. La base de datos se compone de un total de 4,746 registros, estructurados en 12 variables que describen atributos comerciales y físicos esenciales de las viviendas. Entre estas características se encuentran el número de habitaciones, el tamaño total en pies cuadrados, el piso de ubicación, el tipo de área métrica, la ciudad, el estado de amoblamiento, el perfil de inquilino preferido y el número de baños. El objetivo central del proyecto es predecir la variable "Rent", definida como el valor del alquiler mensual, la cual actúa como nuestra etiqueta o variable objetivo. Durante la fase de análisis exploratorio se realizará una auditoría técnica para identificar datos faltantes e inconsistencias en los registros. Las inconsistencias, como valores fuera de rango, formatos incorrectos o registros duplicados, serán tratadas mediante procesos de limpieza. Por otro lado, los valores faltantes serán tratados mediante técnicas de imputación, utilizando la media para variables numéricas y la moda para variables categóricas. Además, si se utilizan variables categóricas, se aplicará One-Hot Encoding para convertir la información de texto en valores numéricos que puedan ser procesados por los modelos.

Desde la perspectiva del modelado computacional, el proyecto se abordará bajo el paradigma de aprendizaje supervisado. Esta elección está plenamente justificada por la naturaleza del conjunto de datos, el cual contiene información etiquetada históricamente donde ya se conoce el valor real de la renta para cada una de las muestras de entrenamiento. Dentro de este paradigma, la configuración experimental corresponde específicamente a un problema de regresión, dado que el sistema no busca encasillar las propiedades en categorías discretas, sino estimar una cantidad numérica continua en el espectro de los precios económicos. Esta aproximación permitirá entrenar diversos modelos para aprender la relación funcional entre los atributos del inmueble y su valor de mercado, buscando minimizar el error predictivo y maximizar la precisión en la estimación de la renta residencial.

II. ESTADO DEL ARTE

El estudio desarrollado por H.Sharma *et al.* [3], aborda el problema de la predicción de precios de vivienda utilizando el conjunto de datos de Ames City, el cual comprende 2930 registros y 82 variables descriptivas. La investigación se centra en identificar el algoritmo con mayor capacidad predictiva e interpretabilidad mediante la comparación de diversos enfoques algorítmicos. El problema se configura como una tarea de regresión dentro del paradigma del aprendizaje supervisado, cuyo objetivo principal es estimar el valor comercial de los inmuebles a partir de un conjunto extenso de características multidimensionales.

En cuanto a la metodología, los autores evaluaron y compararon cuatro modelos fundamentales: Regresión Lineal, Random Forest (RF), XGBoost y Support Vector Regression. Para garantizar la robustez de los resultados, se dividió el conjunto de datos en subgrupos de entrenamiento y prueba, y se aplicó GridSearchCV para el ajuste de hiperparámetros de cada algoritmo. Este procedimiento permitió aislar el rendimiento real de los modelos y mitigar problemas de sobreajuste ante la alta dimensionalidad del dataset de Ames [3]. El desempeño del sistema se cuantificó utilizando el Coeficiente de Determinación (R^2), el Error Absoluto Medio (MAE) y el Error Cuadrático Medio (RMSE). Esta última métrica, fundamental para penalizar las desviaciones de mayor magnitud en las predicciones.

Los resultados experimentales demostraron que el algoritmo XGBoost superó consistentemente a los demás modelos evaluados en configuraciones optimizadas. Mientras que otros modelos como Random Forest alcanzaron un R^2 del 90% (con un RMSE de 2.59 en pruebas comparativas), el modelo XGBoost logró consolidarse como la aproximación más precisa al alcanzar un RMSE de 0.154, destacando su eficiencia técnica y su capacidad de generalización.

El estudio desarrollado por Wang, Zhao y Li [2] aborda el problema de la predicción de precios de alquiler de viviendas en la India utilizando el mismo conjunto de datos seleccionado para este proyecto. La investigación se centra en mejorar la precisión de las estimaciones mediante la combinación de múltiples modelos base a través de técnicas de aprendizaje por conjunto (ensemble learning). El problema se configura como una tarea de regresión dentro del paradigma del aprendizaje supervisado, cuyo objetivo principal es predecir el valor de la renta a partir de diversas características estructurales y categóricas del inmueble.

Para abordar el problema, los autores evaluaron inicialmente cinco modelos base: Gradient Boosting Regression (GBR), Support Vector Regression, Redes Neuronales (NN), K-Nearest Neighbor y Light Gradient Boosting Machine (LGBM). Posteriormente, los tres modelos con mejor desempeño individual (GBR, LGBM y NN) se integraron mediante el método de Stacking, utilizando una Regresión Lineal como meta-regresor para consolidar las predicciones finales. Para la validación de estos modelos, se empleó una división estándar del conjunto de datos, destinando el 80% para el entrenamiento y el 20% para las pruebas. El proceso

incluyó un preprocesamiento riguroso que consistió en la descomposición de la variable híbrida "Floor" en dos características independientes, la eliminación de valores atípicos mediante diagramas de dispersión y la normalización de los datos.

El desempeño del sistema se cuantificó utilizando el Error Cuadrático Medio, el Error Absoluto Medio y el Coeficiente de Determinación (R^2). Adicionalmente, se incluyó el Error Absoluto Medio Porcentual (MAPE) para medir la magnitud relativa de la desviación en términos porcentuales. Los resultados experimentales demostraron que, si bien el modelo GBR fue el más destacado entre los algoritmos individuales, la técnica de *Stacking* superó todos los rendimientos previos. El modelo de ensamble final alcanzó un coeficiente R^2 de 0.8712, un MAE de 0.1485 y un RMSE de 0.3712, consolidándose como la aproximación más precisa y robusta para este problema específico.

Cai y Zhao [1], analizan la predicción del precio de alquiler de viviendas utilizando datos recolectados en seis ciudades de India. El estudio emplea técnicas de aprendizaje supervisado y modelos de regresión lineal múltiple para estimar el valor de renta a partir de variables como el tamaño de la vivienda, número de habitaciones, baños, piso y estado de amueblado. Además, los autores aplican una transformación logarítmica para mejorar el desempeño del modelo. Los resultados muestran que el tamaño de la vivienda y la cantidad de baños son las variables con mayor influencia en el precio del alquiler, mientras que la transformación aplicada permitió mejorar la capacidad predictiva del modelo en la mayoría de las ciudades analizadas.

Pattar *et al.* [4] analizan la predicción de precios de alquiler de viviendas mediante modelos de aprendizaje automático. El estudio incluye etapas de recolección y preparación de datos, así como el entrenamiento de modelos como regresión lineal, árboles de decisión y Random Forest. Los resultados muestran que el sistema puede estimar de manera confiable los valores de renta, facilitando la consulta y evaluación de propiedades. Además, los autores implementan una aplicación que permite generar predicciones automáticas a partir de las características de la vivienda.

III. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

En esta sección se describe el proceso de entrenamiento y evaluación de los modelos de aprendizaje automático implementados para predecir el precio de alquiler de viviendas en India. Se presenta primero la configuración experimental, que incluye la metodología de validación, el preprocesamiento de la variable objetivo, las variables de entrada utilizadas y las métricas de desempeño seleccionadas. Posteriormente se muestran los resultados obtenidos para cada modelo

A. Configuración experimental

La variable *Rent* presenta una asimetría muy alta, lo que significa que la mayoría de propiedades tienen precios bajos pero unas pocas propiedades de lujo tienen precios extremadamente altos, dificultando el aprendizaje del modelo.

Para corregir esto, se aplicó una transformación logarítmica $\log(\text{Rent} + 1)$ como variable objetivo, lo que comprime ese rango tan amplio de precios a una escala más manejable. Una vez que el modelo genera sus predicciones en escala logarítmica, se aplica la función inversa $\exp m l()$ para convertir los resultados nuevamente a rupias indias (INR).

El conjunto de datos procesado consta de 15 variables numéricas de entrada: *BHK*, *Bathroom*, *log_Size*, *Piso_Num*, *Furnishing_Ord*, las seis variables dummy de ciudad (*City_Mumbai*, *City_Delhi*, *City_Bangalore*, *City_Hyderabad*, *City_Chennai*, *City_Kolkata*), *Año*, *Mes* y el indicador de valores atípicos (*es_outlier*). Se excluyeron del entrenamiento los 141 registros marcados como propiedades de lujo (*es_outlier* = 1), que constituyen un segmento de mercado estructuralmente diferente cuya inclusión distorsionaría el modelo del mercado masivo. Para obtener estas representaciones numéricas se aplicaron dos estrategias de codificación: *Ordinal Encoding* para *Furnishing Status*, cuyas categorías presentan un orden natural (*unfurnished* < *semi-furnished* < *furnished*), y *One-Hot Encoding* para *City*, generando las seis variables dummy de ciudad.

La variable *Size* fue transformada como $\log(\text{Size})$ para corregir su asimetría positiva. Una vez definidas las variables de entrada, el conjunto de datos se dividió en 80% para entrenamiento y 20% para prueba. Para evaluar los modelos durante el entrenamiento se utilizó validación cruzada con 5 particiones (K-Fold, $k=5$), aplicada únicamente sobre el conjunto de entrenamiento. Esta misma configuración se empleó dentro de GridSearchCV para seleccionar los hiperparámetros que minimizaran el error absoluto medio en cada modelo.

Las métricas utilizadas para evaluar los modelos fueron el Error Absoluto Medio, que representa el error promedio de predicción expresado en rupias indias (INR), la Raíz del Error Cuadrático Medio, que penaliza con mayor fuerza los errores grandes y permite detectar predicciones muy alejadas del valor real y el R^2 , que indica qué proporción de la variación en los precios logra explicar el modelo. Todas las métricas se reportan con intervalos de confianza al 95 calculados sobre los cinco folds de validación cruzada.

El MAE resulta especialmente interpretable en este contexto al expresar el error promedio directamente en rupias indias (INR), lo que facilita la comprensión práctica del desempeño del modelo para usuarios no técnicos como arrendadores o inquilinos. El RMSE complementa al MAE al penalizar con mayor fuerza las predicciones muy alejadas del valor real, aspecto relevante en un mercado donde los errores grandes pueden implicar decisiones económicas significativas y el R^2 permite evaluar qué proporción de la variabilidad del precio es explicada por el modelo.

Para este proyecto se entrenaron y compararon seis modelos de aprendizaje automático: Regresión Lineal, K-Nearest Neighbors, Árbol de Decisión, XGBoost, Support Vector Regression y una Red Neuronal Artificial. Los hiperparámetros de cada modelo fueron ajustados mediante GridSearchCV,

que evalúa sistemáticamente distintas combinaciones de valores para seleccionar la configuración con menor error. La Tabla I detalla las mallas evaluadas y el mejor valor encontrado para cada caso.

TABLA I
MALLA DE HIPERPARÁMETROS EVALUADA POR MODELO

Modelo	Hiperparámetro	Malla de valores
Regresión Lineal	—	—
KNN	n_neighbors weights metric	[3, 5, 7, 10, 15, 20, 30] [uniform, distance] [euclidean, manhattan]
Árbol de Decisión	max_depth min_samples_split min_samples_leaf criterion	[5, 10, 15, 20, None] [2, 5, 10, 20] [1, 2, 4, 10] [squared_error, absolute_error]
XGBoost	n_estimators max_depth learning_rate subsample	[100, 300, 500] [3, 5, 7] [0.01, 0.05, 0.1] [0.8, 1.0]
SVR	kernel C epsilon gamma	[rbf, poly] [1, 10, 100] [0.01, 0.1] [scale]
Red Neuronal (MLP)	hidden_layer_sizes activation learning_rate_init alpha	[(64,), (128,), (64,32), (128,64), (128,64,32)] [relu, tanh] [0.001, 0.01] [0.0001, 0.001, 0.01]

Para cada modelo, GridSearchCV seleccionó la combinación de hiperparámetros que minimizó el MAE en validación cruzada. Los mejores valores encontrados fueron: KNN con $n_neighbors = 15$ y métrica Manhattan con pesos uniformes; Árbol de Decisión con $max_depth = 10$ y $min_samples_leaf = 10$; XGBoost con $n_estimators = 300$, $max_depth = 3$ y $learning_rate = 0.05$ con subsampling del 80%; SVR con $kernel = rbf$ y $C = 1$; y MLP con arquitectura de 64 neuronas, activación tanh y regularización $\alpha = 0.01$.

Estos hiperparámetros fueron los utilizados para entrenar los modelos finales cuyos resultados se presentan en la Tabla II.

B. Resultados del entrenamiento de Modelos

La Tabla II presenta los resultados de la experimentación para los seis modelos evaluados, incluyendo las métricas de validación cruzada con sus intervalos de confianza al 95%, y los resultados sobre los conjuntos de entrenamiento y prueba para cuantificar el sobreajuste ($\Delta R^2 = R^2_{Train} - R^2_{Test}$).

TABLA II
RESULTADOS DEL ENTRENAMIENTO DE MODELOS

Modelo	MAE CV	RMSE CV	R^2 CV	R^2 Test	R^2 Train	ΔR^2
Regresión Lineal	8,741	17,784	0.7111	0.6676	0.7187	0.0511
IC95%	[8,062–9,419]	[15,589–19,979]				
KNN	8,812	17,527	0.7206	0.6833	0.7338	0.0505
IC95%	[8,338–9,285]	[15,711–19,343]				
Árbol de Decisión	9,000	17,242	0.7302	0.6490	0.7783	0.1292
IC95%	[8,041–9,959]	[15,135–19,349]				
XGBoost	8,232	16,066	0.7655	0.7165	0.8014	0.0849
IC95%	[7,511–8,953]	[14,154–17,979]				
SVR	8,460	16,894	0.7406	0.7207	0.7989	0.0782
IC95%	[7,800–9,119]	[15,164–18,625]				
Red Neuronal (MLP)	8,382	16,698	0.7466	0.7081	0.7542	0.0462
IC95%	[7,670–9,094]	[14,785–18,612]				

Los resultados muestran que SVR con kernel RBF obtuvo el mayor R^2 en prueba (0.7207), seguido de XGBoost (0.7165) y MLP (0.7081). Sin embargo, dado que los intervalos de confianza al 95% de estos tres modelos se solapan considerablemente, las diferencias entre ellos no son estadísticamente concluyentes y los tres constituyen soluciones válidas para el problema. El Árbol de Decisión

individual presentó el mayor sobreajuste ($\Delta R^2 = 0.1292$),

es decir, una diferencia significativa entre su desempeño en entrenamiento ($R^2 = 0.7783$) y en prueba ($R^2 = 0.649$), confirmando que los árboles individuales tienden a memorizar los datos de entrenamiento en lugar de aprender patrones generalizables. La Regresión Lineal, aunque establece una línea base sólida ($R^2_{\text{test}} = 0.6676$) con mínimo sobreajuste ($\Delta R^2 = 0.051$), evidencia que la relación entre las variables de entrada y el precio de arrendamiento no es completamente lineal. SVR fue seleccionado como el mejor modelo por su mayor capacidad de generalización en prueba, atribuible a su regularización fuerte ($C = 1$) que penaliza el sobreajuste y a su kernel RBF, que captura relaciones no lineales entre las variables sin requerir un número elevado de parámetros. XGBoost fue seleccionado como segundo mejor modelo por su consistencia entre validación cruzada ($R^2_{\text{CV}} = 0.7655$, el más alto de todos los modelos) y prueba ($R^2 = 0.7165$), comportamiento esperado dado que el mecanismo de boosting corrige iterativamente los errores de predicción, lo que le permite mantener un buen desempeño tanto en entrenamiento como en datos no vistos. Ambos modelos fueron seleccionados para la etapa de reducción de dimensión.

IV. REDUCCIÓN DE DIMENSIÓN

A. Análisis individual de variables

Para identificar las variables más importantes para la predicción del precio de alquiler, se aplicó un método de selección de tipo filtro basado en la correlación de Pearson entre cada variable de entrada y la variable objetivo $\log(\text{Rent} + 1)$, donde valores cercanos a 1 o -1 indican una relación fuerte con el precio y valores cercanos a 0 indican poca o ninguna relación. Como criterio de selección, se estableció un umbral de $|\rho| < 0.1$, de modo que las variables cuya correlación en valor absoluto no superara dicho umbral serían consideradas candidatas a ser eliminadas del modelo.

Como se observa en la Figura 1, *Bathroom* se consolida como el predictor individual más fuerte ($\rho \approx 0.65$), seguido de *City_Mumbai* ($\rho \approx 0.58$), *BHK* ($\rho \approx 0.55$) y *log_Size* ($\rho \approx 0.52$), confirmando que tanto las características físicas del inmueble como su ubicación geográfica son los factores más determinantes del precio. A partir del umbral establecido, únicamente *City_Delhi* resulta candidata a ser eliminada ($\rho = -0.009$), lo que indica que prácticamente todas las variables aportan información relevante para la predicción del precio de arrendamiento.




Fig. 1. Correlación de Pearson entre cada variable de entrada y $\log(\text{Rent} + 1)$. La línea punteada indica el umbral $|\rho| = 0.1$.

Adicionalmente, el mapa de calor de la Figura 2 revela multicolinealidad entre *BHK*, *log_Size* y *Bathroom*, con correlaciones entre 0.70 y 0.77, lo cual es esperado dado que propiedades más grandes tienden a tener más habitaciones y baños simultáneamente.




Fig. 2. Mapa de calor de correlaciones entre variables de entrada. Se observa multicolinealidad entre *BHK*, *log_Size* y *Bathroom*.

La multicolinealidad detectada entre *BHK*, *log_Size* y *Bathroom* sugiere que estas tres variables capturan en gran medida la misma información, lo que justifica explorar técnicas de reducción de dimensión para simplificar el modelo sin perder capacidad predictiva.

B. Extracción de características lineal

Se aplicó el Análisis de Componentes Principales (PCA) como técnica de extracción de características lineal. El criterio utilizado para seleccionar el número de componentes fue retener el 95% de la varianza explicada acumulada, determinado a partir de la curva de varianza explicada. Bajo este criterio, el espacio de características se redujo de 15 variables originales a 10 componentes principales, logrando una reducción del 33.3% en la dimensionalidad.




Fig. 3. Varianza explicada acumulada por número de componentes principales. La línea punteada indica el umbral del 95%, alcanzado con 10 componentes.

Los dos mejores modelos obtenidos en la sección anterior, XGBoost y SVR, fueron reentrenados y evaluados sobre las componentes obtenidas por PCA. XGBoost presentó una mejora marginal en R^2_{test} al pasar de 0.7165 a 0.7233, lo que sugiere que la eliminación de ruido mediante PCA beneficia levemente su capacidad de generalización. SVR

en cambio redujo su R^2 test de 0.7207 a 0.7061, indicando que la transformación lineal de PCA elimina información relevante para su función de kernel RBF, la cual opera directamente sobre las distancias en el espacio original de características.

TABLA III
SELECCIÓN DEL NÚMERO DE COMPONENTES PCA

Modelo	Variables	% Reducción	R^2 CV [IC95%]	R^2 Test	R^2 Train	ΔR^2
XGBoost Original	15	—	0.7655 [0.7300, 0.8010]	0.7165	0.8014	0.0849
XGBoost + PCA	10	33.3%	0.7511 [0.7156, 0.7867]	0.7233	0.8040	0.0807
SVR Original	15	—	0.7406 [0.7009, 0.7803]	0.7207	0.7989	0.0782
SVR + PCA	10	33.3%	0.7406 [0.7009, 0.7803]	0.7061	0.7785	0.0724

En términos generales, PCA logra una reducción significativa de dimensionalidad con un impacto mínimo en el desempeño predictivo, lo que lo convierte en una alternativa válida cuando se prioriza la eficiencia computacional sobre la precisión máxima.

C. Extracción de características no lineal

Se aplicó UMAP (Uniform Manifold Approximation and Projection) como técnica de extracción de características no lineal.

Para seleccionar el número óptimo de componentes se evaluaron cuatro opciones [2, 5, 8, 10], entrenando XGBoost sobre cada representación y midiendo el R^2 en validación cruzada. Como se observa en la Tabla IV, el valor de 8 componentes fue el que produjo el mejor desempeño (R^2 CV = 0.6858), logrando una reducción del 46.7% respecto a las 15 variables originales.

TABLA IV
SELECCIÓN DEL NÚMERO DE COMPONENTES UMAP

Componentes	R^2 CV
2	0.6638
5	0.6788
8	0.6858
10	0.6816

Los dos mejores modelos, XGBoost y SVR, fueron reentrenados sobre las 8 componentes obtenidas. La Tabla V presenta los resultados completos. Ambos modelos mostraron una caída significativa en el desempeño. XGBoost redujo su R^2 test de 0.7165 a 0.6355, y SVR cayó de 0.7207 a 0.5589, una pérdida de más de 16 puntos porcentuales. Esto indica que las relaciones no lineales que UMAP preserva no corresponden a la estructura que determina el precio de arrendamiento, por lo que la proyección destruye información predictiva relevante. La reducción del sobreajuste observada en ambos modelos no es consecuencia de una mejor generalización sino de un modelo subajustado.

TABLA V
RESULTADOS DE LOS MODELOS CON UMAP

Modelo	Variables	% Reducción	R^2 CV [IC95%]	R^2 Test	R^2 Train	ΔR^2
XGBoost Original	15	—	0.7655 [0.7300, 0.8010]	0.7165	0.8014	0.0849
XGBoost + UMAP	8	46.7%	0.6858 [0.6427, 0.7289]	0.6355	0.7148	0.0793
SVR Original	15	—	0.7406 [0.7009, 0.7803]	0.7207	0.7989	0.0782
SVR + UMAP	8	46.7%	0.5907 [0.5410, 0.6405]	0.5589	0.5947	0.0358

Estos resultados confirman que UMAP no es la técnica de reducción más adecuada para este problema: aunque logra la mayor reducción dimensional (46.7%), lo hace a costa de destruir información predictiva relevante, por lo

que el espacio original de características sigue siendo la representación más competitiva para ambos modelos.

V. DISCUSIÓN Y CONCLUSIONES

Los resultados obtenidos muestran que SVR y XGBoost son los modelos con mejor capacidad de generalización, aunque sus intervalos de confianza se solapan con los de MLP, por lo que las diferencias entre estos tres modelos no son estadísticamente concluyentes. El Árbol de Decisión individual fue el más débil, con el mayor sobreajuste ($\Delta R^2 = 0.129$), confirmando que los árboles individuales son inferiores a los ensambles en este tipo de problema.

Respecto a la reducción de dimensión, PCA demostró ser la técnica más adecuada: con solo 10 componentes logró una reducción del 33.3% con un impacto mínimo en el desempeño. UMAP en cambio resultó perjudicial, lo que sugiere que la estructura latente del dataset es predominantemente lineal y que una transformación no lineal no aporta información adicional relevante para la predicción del precio.

Comparando con el estado del arte, Wang et al. [2] reportaron un $R^2 = 0.8712$ utilizando Stacking sobre el mismo dataset, superando los resultados de este proyecto. Esta diferencia se explica porque el Stacking combina múltiples modelos base para corregir errores individuales, otorgándole mayor capacidad predictiva que cualquier modelo individual. Cai y Zhao [1] encontraron que el tamaño de la vivienda y el número de baños son las variables más influyentes, resultado consistente con los hallazgos de este proyecto donde *Bathroom* ($\rho \approx 0.65$) y *log_Size* ($\rho \approx 0.52$) se consolidaron como los predictores más fuertes. Sharma et al. [3] reportaron que XGBoost superó consistentemente a los demás modelos en su estudio, lo cual es coherente con los resultados obtenidos aquí donde XGBoost fue el segundo mejor modelo en prueba. Finalmente, Pattar et al. [4] demostraron que modelos simples como Regresión Lineal pueden estimar confiablemente los valores de renta, resultado que también se observa aquí con un R^2 test de 0.6676.

En cuanto a las conclusiones, la ubicación geográfica y las características físicas del inmueble, especialmente el número de baños, resultaron ser los factores más determinantes del precio. PCA demostró ser la técnica de reducción de dimensión más adecuada para este problema, logrando una reducción del 33.3% con un impacto mínimo en el desempeño. UMAP no resultó apropiado para este dataset, ya que su proyección no lineal destruyó información predictiva relevante, especialmente para SVR. Adicionalmente, el análisis exploratorio confirmó que el dataset no presenta valores faltantes en ninguna de sus 12 variables, lo que permitió trabajar directamente con los datos originales sin necesidad de imputación.

Como trabajo futuro, la incorporación de técnicas de ensemble como Stacking, la inclusión de variables adicionales como proximidad a zonas comerciales o transporte público, y la exploración de modelos más avanzados como LightGBM.

REFERENCIAS

- [1] Z. Cai and Y. Zhao, "House rent analysis with linear regression model: A case study of six cities in india," *Highlights in Science, Engineering and Technology*, vol. 38, pp. 576–582, 2023.
- [2] K. Wang, H. Zhao, and J. Li, "Machine learning-based house rent prediction using stacking integration method," *American Journal of Management Science and Engineering*, vol. 8, no. 2, pp. 50–55, 2023.
- [3] H. Sharma, H. Harsora, and B. Ogunleye, "An optimal house price prediction algorithm: Xgboost," *Analytics*, vol. 3, pp. 30–45, 2024.
- [4] G. G. Pattar, D. G. Savakar, and A. Deshapande, "House rent prediction using machine learning," *International Journal of Engineering Development and Research (IJEDR)*, vol. 13, no. 4, pp. 693–696, 2025.